Тема „Линейная регрессия"

от лат. regressio „возвращение, движение назад"

Модель предсказывает число

$\hat{y} = w \cdot x + b$, где w - веса

b - смещение

Суммарная ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

квадрат нужен, чтобы:

1) убрать знак

2) усиливает ошибку → модель получает сигнал, когда допускает крупных промах

Тема „LogLoss"

если $y=1$: $L = -\log(p)$

если $y=0$: $L = -\log(1-p)$

Данное р-е показывает модель

за уверенные и ошибочные ответы

Тема „Логистическая регрессия"

$z = w \cdot x + b$ # линейная часть

$p = \sigma(z) = \frac{1}{1+e^{-z}}$

сигмоида

$\sigma(z) = \frac{e^z}{e^z+1}$, выходит это $0 < \sigma(z) < 1$

Тема „Градиентный спуск"

Это поиск минимума ф-и потерь $L(w)$ → шаг за шагом приближаемся к минимуму.

$$w_{t+1} = w_t - \alpha \cdot \nabla L(w_t),$$

∇ – оператор градиента.

α – learning rate; коэффициент, который управляет размером шага

w_t – текущие веса

Тема „Нормализация"

Приведение признаков к одному масштабу.

Два основных способа:

1) Z-score

$$z = \frac{x - \mu}{\sigma}, \quad \mu - \text{ср. признака}$$

σ - стандартное отклонение

среднее $(z) = 0 =$ среднее $(a \cdot x + b) = a \cdot \mu + b$ (1)

отклонение $(z) = 1 =$ отклонение $(ax + b) = |a| \sigma$ (2)

из (1) и (2) получаем $b = -\frac{\mu}{\sigma}$, $a = \frac{1}{\sigma}$

и итог:

$$z = ax + b = \left(\frac{1}{\sigma}\right) \cdot x - \frac{\mu}{\sigma} = \frac{x - \mu}{\sigma}$$

2) Min-max

$$x_{minmax} = \frac{(x - min)}{max - min} \rightarrow$$ логика та же,

Это и у Z-score

После такого преобразования

min = 0 , max = 1

Z-score ~~более~~ менее чувствителен к выбросам

Потому что min-max берет крайние значения, а Z-score считает по всем точкам сразу и выброс может быть "размыт"